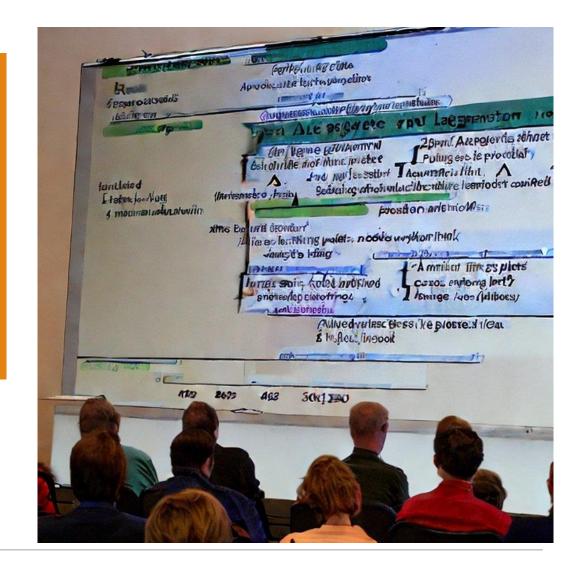


LLMs e IA Generativa Clase 7 – Agentes y Fine Tuning

Mg. Ing. Ezequiel Guinsburg ezequiel.guinsburg@gmail.com





Referencias:

- [1] Wei et al. "Chain of thought prompting elicits reasoning in large language models." NeurIPS 2022
- [2] Yao et al. <u>"Tree of Thoughts: Dliberate Problem Solving with Large Language Models."</u> arXiv preprint arXiv:2305.10601 (2023).
- [3] Liu et al. "Chain of Hindsight Aligns Language Models with Feedback" arXiv preprint arXiv:2302.02676 (2023).
- [4] Liu et al. <u>"LLM+P: Empowering Large Language Models with Optimal Planning Proficiency"</u> arXiv preprint arXiv:2304.11477 (2023).
- [5] Yao et al. <u>"ReAct: Synergizing reasoning and acting in language models."</u> ICLR 2023.
- [6] Ejemplo completo de aplicación de agentes: https://github.com/Significant-Gravitas/AutoGPT

Temas:




- Pendientes de clase 7: Estrategias de segmentación del texto.
 RAGas.
- Concepto de Agentes y su utilización práctica.
- Fine tuning de grandes modelos de lenguaje.
- Ejercicio práctico.

Segmentación de texto pre-embeddings:

Distintas estrategias:

- División en párrafos u oraciones (depende máximo de Tokens que acepte el modelo de embeddings (ej.: 512 K, 2048 K, etc.).
- Segmentación por Chunking, largo fijo (ejemplo en repo "eguins").
- Segmentación por contexto semántico (Smart parsing). Referencia.
- Segmentación por ventanas deslizantes por contexto semántico.



RAGas (Retrieval-Augmented Generation Assessment)

Framework para evaluar sistemas RAG, utilizando métricas basadas en LLMs y tradicionales.

Repo: https://github.com/explodinggradients/ragas

Ejemplo: https://towardsdatascience.com/evaluating-rag-applications-with-

ragas-81d67b0ee31a


	question	contexts	answer	ground_truths	context_precision	context_recall	faithfulness	answer_relevancy
•	What did the president say about Justice Breyer?	['Tonight, I'd like to honor someone who has dedicated his life to serve this country: Ju 'And I did that 4 days ago, when I nominated Circuit Court of Appeals Judge Ketanji B 'A former top litigator in private practice. A former federal public defender. And from a	service and referred to him as an Army veteran,	['The president said that Justice Breyer has dedicated his life to serve the country and thanked him for his service.']	0.50	1.00	1.00	0.85
1	What did the president say about Intel's CEO?	['But that's just the beginning. \n\nintel's CEO, Pat Geisinger, who is here tonight, told r'This is where Intel, the American company that helped build Silicon Valley, is going to 'For the past 40 years we were told that if we gave tax breaks to those at the very top,	specifically in the given context.	["The president said that Pat Gelsinger is ready to increase Intel's investment to \$100 billion."]	0.00	1.00	0.50	0.83
1	What did the president say about gun violence?	['And I ask Congress to pass proven measures to reduce gun violence. Pass universal i 'As I said last year, especially to our younger transgender Americans, I will always have 'Let's stop seeing each other as enemies, and start seeing each other for who we really	measures to reduce gun violence, including	[The president asked Congress to pass proven measures to reduce gun violence."]	1.00	1.00	1.00	0.91

Agentes:




Concepto:


Sistemas o programas que interactúan con un entorno o realizan tareas específicas de manera autónoma, tomando decisiones basadas en la información que tienen a su disposición.



Agentes:

Ejemplo: ReAct






Referencia [5] Yao et al. "ReAct: Synergizing reasoning and acting in language models." ICLR 2023.




Agentes:

.UBAfiuba PERCUITAD DE INGENIERÍA

Search Tool





LLM Model Fine Tuning:



- Cuando usarlo?! (prompting Vs. RAG Vs. Fine tuning) -> Clase 8
- Huggingface Transformers / Spacy models fine tuning
- OpenAl fine tuning

LLM Model Fine Tuning - Huggingface Transformers / Spacy models fine tuning

Ejemplos de uso:

- Clasificación de texto
- Respuestas a preguntas
- Generación de texto
- Traducción
- NER (Named Entity Recognition)
- Resumen (summarization)





(https://platform.openai.com/docs/guides/fine-tuning/)

Disponibles: gpt-40, 4º mini, 3.5 turbo

Casos de uso:

- a) Establecer el estilo, tono, formato u otros aspectos cualitativos.
- b) Mejorar la confiabilidad al generar una salida deseada.
- c) Corregir fallos al seguir indicaciones complejas.
- d) Manejar situaciones específicas.
- e) Generar una nueva habilidad o tarea que sea difícil de articular en una indicación.





(https://platform.openai.com/docs/guides/fine-tuning/)

Ejemplo de preparación de datos (json):

Validación del dataset: https://cookbook.openai.com/examples/chat-finetuning-data-prep-



LLM Model Fine Tuning: OpenAl VISION fine tuning

Modelo de dato de entrenamiento --->

```
"messages": [
 { "role": "system", "content": "Eres un asistente que identifica quesos poco comunes."
 { "role": "user", "content": "¿Qué es este queso?" },
 { "role": "user", "content": [
       "type": "image url",
       "image url": {
         "url": "https://upload.wikimedia.org/wikipedia/commons/3/36/Danbo Cheese.jpg"
   "role": "assistant", "content": "Danbo" }
```

<u>Restricciones</u>: Máximo 50k ejemplos. Cada ejemplo máximo 10 imágenes. Cada imagen máximo 10 MB <u>Formatos</u>: JPEG. PNG, WEBP (RGB / RGBA).

Policy: So se puede entrenar con imágenes de personas, caras, chicos ni CAPTCHAs

LLM Model Fine Tuning: OpenAl fine tuning



Crear modelo --->

```
from openai import OpenAI
client = OpenAI()

client.fine_tuning.jobs.create(
   training_file="file-abc123",
   model="gpt-4o-mini-2024-07-18"
)
```

Hiperparámetros--->

- Batch Size (cuanto mayor menor es la varianza)
- Learning Rate Multiplier (Factor de escala del learning rate)
- n_epochs (un epoch es un ciclo entero del dataset)

LLM Model Fine Tuning: precios OpenAl / modelos Llama



Precios OpenAl ->

gpt-4o-2024-08-06

\$10.00 / 1M output tokens

\$5.00 / 1M output tokens

\$2.50 / 1M input tokens

\$1.25 / 1M input tokens

\$1.25 / 1M cached** input tokens

\$10.00 / 1M output tokens

\$5.00 / 1M output tokens

Model

Pricing

Pricing with Batch API*

gpt-4o-2024-08-06

\$3.750 / 1M input tokens

\$1.875 / 1M input tokens

\$1.875 / 1M cached** input tokens

\$15.000 / 1M output tokens

\$7.500 / 1M output tokens

Framework de fine tuning para modelos Llama ->

https://github.com/pytorch/torchtune

Ejercicio en clase:



- Sobre el trabajo de la clase 6: implementar un sistema de agentes para que responda de manera eficiente dependiendo de qué persona se está preguntando (1 agente por persona).
- Entregables: Link a repo público y captura de video de chatbot consultando los CVs de los integrantes del equipo. Por defecto, cuando no se nombra a nadie en la query, utilizar el Agente del alumno.

PLUS: Si se consulta por más de un CV, traer el contexto de cada uno y responder de manera acorde.